Laporan Ringkas Infrastruktur Sistem

Ringkasan

Sistem berjalan pada satu instans EC2 free tier dengan dua komponen utama: backend FastAPI dan frontend Next.js. Basis data memakai SQLite untuk metadata dan ChromaDB untuk indeks vektor, keduanya persisten di volume utama.

Kinerja

Latensi rata-rata respons chat 1,8 detik pada jam sibuk. Tingkat cache hit mencapai 62% untuk pertanyaan yang berulang. Penggunaan CPU rata-rata 35%, kapasitas memori 512 MB dari 1 GB yang tersedia.

Ketersediaan

Target uptime 99% per bulan. Insiden terakhir terjadi pada tanggal 12 Agustus, berdurasi 14 menit, disebabkan pembaruan TLS yang gagal dan sudah diperbaiki dengan skrip rollback otomatis.

Rekomendasi

Pertimbangkan penambahan cache Redis saat trafik melewati 50 permintaan per menit, dan migrasi ke Supabase saat diperlukan replikasi multi-instans.